

ОТЧЕТ ПО ЛАБОРАТОРНОЙ РАБОТЕ

Кейсы 4 и 7

Регрессия по функциональным данным через линейные функционалы
и построение аддитивной модели

Код и ноутбуки: https://github.com/Arsenyuya/MetOpt_project

2026

Аннотация

В работе исследуются два способа сведения сложных регрессионных задач к линейному оцениванию параметров. В кейсе 4 функции заменяются конечным набором интегральных признаков. В кейсе 7 многомерная зависимость представляется суммой одномерных компонент. Для обоих кейсов проведены вычислительные эксперименты на синтетических данных, сопоставлены модели и исследовано влияние сложности представления.

Воспроизводимость

Исходный код и выполненные ноутбуки опубликованы в открытом репозитории: https://github.com/Arsenyuya/MetOpt_project. Основные эксперименты используют `random_state = 42`.

Численные результаты получены при фиксированном `random_state = 42` и проверены повторным запуском ноутбуков.

1. Введение

В работе рассматриваются два учебных кейса, связанные с построением регрессионных моделей для функциональных и многомерных данных. В кейсе 4 исходным объектом является функция на отрезке $[0,1]$, а в кейсе 7 многомерная зависимость приближается суммой одномерных компонент.

Цель работы: исследовать переход от функциональных данных к конечной системе признаков и проверить возможности и ограничения аддитивной модели.

2. Кейс 4

2.1 Постановка задачи

Для каждого объекта задана функция

$$x_i(t) = a_i \sin(2\pi t) + b_i \cos(2\pi t) + c_i t + \epsilon_i(t), \quad t \in [0,1].$$

Ответ генерируется через интегральный функционал:

$$y_i = 2 \int_0^1 x_i(t) \sin(2\pi t) dt - \int_0^1 x_i(t) t dt + \eta_i.$$

Нужно по дискретным значениям функций построить конечную матрицу признаков и обучить регрессионную модель.

2.2 Метод

Функциональные признаки строятся как интегралы

$$z_{ik} = \int_0^1 x_i(t) \phi_k(t) dt.$$

В работе используются два набора ϕ_k : индикаторы подотрезков и тригонометрические функции. После построения матрицы Z задача сводится к обычной линейной регрессии.

Обозначим через $X = [1, Z]$ матрицу с единичным столбцом, а через $\beta = (\beta_0, \beta_1, \dots, \beta_m)^T$ вектор параметров. Матричная форма модели:

$$y = X\beta + \epsilon.$$

МНК минимизирует $\|y - X\beta\|_2^2$. Нормальные уравнения и решение имеют вид

$$X^T X \beta = X^T y, \quad \beta = (X^T X)^{-1} X^T y.$$

Явная формула применима, если столбцы X линейно независимы и $X^T X$ обратима. Иначе используют псевдообратную матрицу или регуляризацию.

Функционал $L_\phi(x) = \int_0^1 x(t)\phi(t) dt$ является линейным:

$$L_\phi(\alpha x_1 + \gamma x_2) = \alpha L_\phi(x_1) + \gamma L_\phi(x_2),$$

поскольку интеграл линейно распределяется по сумме и постоянным множителям. Локальное среднее также линейно, так как отличается от интеграла только делением на постоянную длину подотрезка.

Если $w(t) = \sum_{k=1}^m \beta_k \phi_k(t)$, то

$$\sum_{k=1}^m \beta_k \int_0^1 x_i(t) \phi_k(t) dt = \int_0^1 x_i(t) w(t) dt.$$

Значит, конечная линейная модель эквивалентна интегрированию исходной функции с приближенной функцией весов.

В Ridge свободный член не штрафуются. Для $P = \text{diag}(0, 1, \dots, 1)$ решение записывается как

$$\beta_\lambda = (X^T X + \lambda P)^{-1} X^T y.$$

Добавка λP уменьшает влияние плохо определенных направлений и делает коэффициенты устойчивее. Слишком большая регуляризация, наоборот, чрезмерно уменьшает коэффициенты и ухудшает прогноз.

2.3 Эксперименты

Параметры основного эксперимента: 320 функций, 120 точек сетки, тестовая доля 0.25, 10 функционалов и $\lambda = 0.1$. Сравниваются МНК и Ridge, два набора функционалов, разное число функционалов, значения λ , уровни шума и плотности сетки.

2.4 Результаты




Рисунок 1. Примеры сгенерированных функциональных наблюдений.




Рисунок 2. Истинные и предсказанные значения OLS.




Рисунок 3. Истинная и восстановленные функции весов.




Рисунок 4. Зависимость ошибки от числа функционалов.




Рисунок 5. Зависимость качества от параметра регуляризации.

Таблица 1. Качество моделей кейса 4 на тестовой выборке

Модель	Функционалы		MSE test	RMSE test	R2 test
OLS	средние подотрезках	на	0.0105	0.1025	0.9937
Ridge	средние подотрезках	на	0.0103	0.1015	0.9938
OLS	тригонометрические		0.0104	0.1017	0.9938
Ridge	тригонометрические		0.0101	0.1006	0.9939

Таблица 2. Устойчивость коэффициентов по 30 разбиениям

Функционалы	Модель	Среднее коэффициентов	std	Максимальное коэффициентов	std	Среднее число обусловленности
средние подотрезках	на OLS	0.0843		0.0996		93.8591
средние подотрезках	на Ridge	0.0541		0.0647		93.8591
тригонометрические	OLS	0.3435		0.6006		185.8844
тригонометрические	Ridge	0.0292		0.0466		185.8844

В ноутбуке представлены следующие подписанные графики:

Все модели из таблицы 1 дали близкое качество. Лучший результат у Ridge с тригонометрическими признаками: $RMSE=0.1006$ и $R^2=0.9939$. Тригонометрический базис естественно описывает синусоидальную часть генерации и лучше восстанавливает гладкую функцию весов. Кусочно-постоянная оценка передает общий ход, но остается ступенчатой.

Минимум test-MSE при переборе числа функционалов достигается примерно при $m=6$. При росте до $m=20$ train-ошибка уменьшается, а test-ошибка возрастает до 0.0106 для локальных средних и до 0.0110 для тригонометрических признаков. Это указывает на слабое переобучение.

Для Ridge наименьший test-RMSE 0.1005 получен при $\lambda \sim 0.0464$. Значение 0.1 находится рядом с минимумом. При $\lambda > 1$ качество быстро ухудшается из-за слишком сильного штрафа.

Ridge особенно сильно стабилизирует коэффициенты тригонометрической системы: среднее стандартное отклонение уменьшается с 0.3435 до 0.0292. Это важно, поскольку среднее число обусловленности этой матрицы выше. При этом абсолютные коэффициенты разных систем нельзя напрямую сравнивать из-за разных масштабов признаков.

В проверке устойчивости к шуму и сетке test-RMSE остается в узком диапазоне 0.0947...0.0980. Увеличение сетки с 50 до 200 точек не дало улучшения, поэтому для данного эксперимента уже 50–120 точек достаточно.

2.5 Вывод по кейсу 4

Интегральные признаки успешно переводят функциональные данные в обычную регрессионную задачу. Для данной генерации обе системы функционалов дают высокое качество, но тригонометрическая система лучше соответствует форме истинной функции весов. Небольшая Ridge-регуляризация заметно повышает устойчивость коэффициентов почти без потери точности.

3. Кейс 7

3.1 Постановка задачи

Для признаков $X \in [0,1]^p$ рассматривается аддитивная модель

$$y = \beta_0 + \sum_{j=1}^p g_j(x_j).$$

На аддитивных данных ответ задается как

$$y = \sin(2\pi x_1) + 0.5(x_2 - 0.5)^2 + \exp(-3x_3) + \epsilon.$$

Отдельно проверяется неаддитивный случай:

$$y = \sin(2\pi(x_1 + x_2)) + 0.5x_3 + \epsilon.$$

3.2 Метод

Каждая компонента приближается полиномиальным базисом:

$$g_j(x_j) = \sum_{k=1}^M \theta_{jk} x_j^k.$$

Блоки степеней всех признаков объединяются в матрицу Z , после чего параметры оцениваются с помощью МНК или Ridge. Компоненты центрируются, поскольку константу можно переносить между g_j и свободным членом без изменения предсказаний.

3.3 Эксперименты

Параметры основного эксперимента: 450 объектов, 3 признака, тестовая доля 0.25, шум 0.10, 6 базисных функций на признак и $\lambda = 0.01$ для Ridge-моделей. Аддитивная модель сравнивается с линейной и полной полиномиальной моделями. Также проверяется влияние M и качество на неаддитивных данных.

3.4 Результаты




Рисунок 6. Предсказания линейной модели на аддитивных данных.




Рисунок 7. Истинные и восстановленные центрированные компоненты.




Рисунок 8. Влияние числа базисных функций на качество.



Рисунок 9. Аддитивная модель на неаддитивных данных.

Таблица 3. Качество моделей кейса 7 на тестовой выборке

Данные	Модель	Параметры	MSE test	RMSE test	R2 test
Аддитивные	Linear	4	0.2245	0.4739	0.6120
Аддитивные	Additive OLS	19	0.0114	0.1068	0.9803
Аддитивные	Additive Ridge	19	0.0232	0.1523	0.9599
Аддитивные	Polynomial Ridge	20	0.0281	0.1676	0.9515
Неаддитивные	Linear	4	0.5450	0.7383	0.1147

Данные	Модель	Параметры	MSE test	RMSE test	R2 test
Неаддитивные	Additive Ridge	19	0.5824	0.7631	0.0540
Неаддитивные	Polynomial Ridge	20	0.2625	0.5123	0.5737

В ноутбуке представлены:

На аддитивных данных Additive OLS снизила test-RMSE с 0.4739 у линейной модели до 0.1068 и повысила R^2 до 0.9803. Additive Ridge немного лучше полной Polynomial Ridge при почти одинаковом числе параметров: RMSE=0.1523 против 0.1676. Лишние взаимодействия не дают преимущества, когда истинная зависимость аддитивна.

После центрирования максимальная разница предсказаний равна $4.9 \cdot 10^{-15}$, то есть представление компонент изменилось без изменения модели. Восстановленные функции передают ожидаемые формы: g_1 синусоидальна, g_2 имеет слабую U-образную форму, а g_3 убывает. Лучше всего восстановлена g_3 ; у g_1 заметна ошибка на краю отрезка, а малый эффект g_2 оценивается менее уверенно.

При $M=1$ и $M=2$ модель недообучается: test-RMSE около 0.474. Начиная с $M=3$ ошибка резко уменьшается, минимум на проверенной сетке достигается при $M=10$ (RMSE=0.1196), а при $M=12$ ошибка немного растет. Поэтому разумный диапазон для этого эксперимента — $M=5 \dots 10$; $M=6$ является понятным компромиссом между качеством и сложностью.

На неаддитивных данных Additive Ridge не может учесть совместный эффект x_1 и x_2 и получает $R^2=0.0540$. Полная полиномиальная модель содержит взаимодействия и повышает R^2 до 0.5737, хотя полином третьей степени тоже не полностью описывает синусоидальную зависимость.

3.5 Вывод по кейсу 7

Аддитивная модель хорошо работает, когда отклик действительно является суммой одномерных нелинейных эффектов. Она точнее линейного baseline и проще для интерпретации, чем полная модель с взаимодействиями. Главное ограничение проявляется на неаддитивных данных: взаимодействия нельзя восстановить суммой отдельных компонент.

4. Общее заключение

Оба кейса показывают, что удачное представление данных может свести сложную задачу к линейному оцениванию параметров. В кейсе 4 ключевым шагом является выбор функционалов, а в кейсе 7 — выбор базиса для одномерных компонент. Регуляризация помогает при неустойчивых признаках, но ее параметр нельзя делать слишком большим.

Ограничения экспериментов: данные синтетические, рассмотрено одно основное разбиение train/test и небольшие сетки гиперпараметров. Продолжить работу можно с помощью кросс-валидации, сплайнов вместо степенного базиса и проверки на реальных данных.

5. Использование ИИ

Публичная ссылка: <https://chatgpt.com/share/6a22a804-d9c0-8387-9840-ffab586ea4a1>

Инструмент: ChatGPT

Часть проекта: README / Colab setup / smoke tests / docstrings

Конкретная помощь: техническое оформление

Что принято: README / smoke tests / docstrings

Что изменено вручную с референсом: Colab setup

Что проверено вручную: запуск тестов, запуск ноутбуков, просмотр diff, проверка что выводы и результаты не изменились

6. Источники и заимствования

- Условия кейсов 4 и 7 и требования к отчету предоставлены преподавателем.
- Использованные программные библиотеки перечислены в requirements.txt.
- В текущем тексте нет вставленных фрагментов из внешних источников; формулы

МНК и Ridge являются стандартными формулами курса.